Курсовая работа
Тема: Повторяющиеся отмеченные временные точечные процессы и их применение для прогнозирования событий в медицинских данных.
Topic: Repetitive time-based point processes and their application to predicting events in medical data.

Аннотация

В данной работе исследуется применение модели RMTPP (Recurrent Marked Temporal Point Processes) для прогнозирования времени следующего измерения уровня глюкозы в крови, а также показателя уровня сахара. Это новый подход в прогнозировании уровня глюкозы в крови. Разработанная модель адаптирована для работы с медицинскими временными рядами. Модель обучалась на сгенерированном датасете, моделирующий человека с диабетом 1 типа, который проводит измерения с частотой, зависящей от показаний глюкозы в крови.

Введение

Исследование посвящено применению повторяющихся отмеченных временных точечных процессов (Recurrent Marked Temporal Point Processes, RMTPP) для прогнозирования событий в медицинских данных. Основная задача заключается в разработке модели RMTPP, способной предсказывать время следующего измерения уровня глюкозы, а также ожидаемый уровень глюкозы.

Мотивация исследования

В области прогнозирования диабета работают ведущие специалисты, каждый из которых внес значительный вклад. Сьюзан Мерфи (Гарвард) занимается разработкой адаптивных вмешательств в медицине. Дэвид Сонтаг (MIT) исследует применение методов машинного обучения для анализа медицинских временных рядов. Питер Джейкобс (OHSU) специализируется на системах поддержки принятия решений (DSS) для пациентов с диабетом 1 типа. Клара Бергер (ETH Zürich) разрабатывает физиологические модели динамики глюкозы, а Борис Ковачев (UVA) известен созданием широко используемого симулятора UVA-Padova.

Сахарный диабет 1 типа (СД1) — хроническое заболевание, характеризующееся отсутствием выработки инсулина поджелудочной железой. За последнее столетие подходы к его лечению претерпели значительные изменения. В 1920-х годах, после открытия инсулина, терапия заключалась в его ручном введении без точного контроля уровня глюкозы. В 1980-х появились первые глюкометры и инсулиновые помпы, что позволило частично персонализировать лечение. К 2000-м годам широкое распространение получили системы непрерывного мониторинга глюкозы (CGM) и полуавтоматические помпы. В 2010-х начали внедряться автоматизированные системы доставки инсулина (AID), такие как Medtronic 670G, однако их использование остается ограниченным из-за высокой стоимости и недостаточной удобности.

Несмотря на технологический прогресс, ключевая проблема терапии СД1 сохраняется: расчет необходимых доз инсулина остается сложным и сопряжен с рисками для пациентов. Исследования показывают, что около 64% пациентов допускают ошибки в определении дозировки, что приводит к опасным колебаниям уровня

глюкозы — гипо- и гипергликемии. Основные трудности связаны с необходимостью учитывать множество факторов, включая потребление углеводов, индивидуальную чувствительность к инсулину, текущий уровень глюкозы и физическую активность.

В последние годы для решения этих проблем активно применяются методы искусственного интеллекта (ИИ) и машинного обучения (МО). Одним из ключевых направлений является автоматизация расчета доз инсулина. Традиционные методы, такие как многократные инъекции (MDI) или использование помп без AID, основаны на эвристических правилах, которые не всегда учитывают динамические изменения состояния пациента. Алгоритмы на основе ИИ анализируют данные CGM, историю введенных доз, потребление углеводов и другие параметры, предоставляя персонализированные рекомендации в реальном времени.

Еще одной важной задачей является прогнозирование гипогликемии — критического состояния, при котором уровень глюкозы опускается ниже 70 мг/дл. Предсказать его заранее сложно, однако современные модели на основе рекуррентных нейронных сетей (RNN) способны выявлять риски за 30–120 минут до наступления гипогликемии, используя данные мониторинга глюкозы и показатели активности.

Кроме того, ИИ позволяет адаптировать терапию с учетом изменений инсулинорезистентности и чувствительности пациента. В отличие от традиционного подхода, при котором коррекция доз проводится врачом раз в несколько месяцев, алгоритмы машинного обучения непрерывно анализируют данные и предлагают ежедневные корректировки базальных и болюсных доз, что повышает точность и безопасность терапии.

Реализованные модели систем поддержки принятия решений (DSS) для управления диабетом

Современные системы поддержки принятия решений для управления сахарным диабетом можно разделить на две основные категории: модели, предоставляющие рекомендации по коррекции доз инсулина, и модели, ориентированные на прогнозирование и профилактику гипогликемии.

Модели для коррекции уровня инсулина включают:

1. **Физиологические модели** - используют математическое описание метаболических процессов организма, учитывая кинетику инсулина и динамику глюкозы. Эти модели требуют точных индивидуальных параметров пациента.

2. **Модели на основе кластеризации** - анализируют базы данных исторических случаев, находя похожие клинические ситуации и предлагая решения, которые работали для аналогичных пациентов.

3. **Эвристические алгоритмы** - основаны на наборе заранее определенных правил и логических условий, часто разработанных на основе клинических рекомендаций и экспертного опыта.

4. **Модели машинного обучения** - используют методы искусственного интеллекта для анализа больших массивов клинических данных, выявляя сложные закономерности и взаимосвязи между различными параметрами.

5. **Алгоритмы оценки питания** - специализируются на определении количества углеводов в пище и времени ее приема, что критически важно для расчета болюсного инсулина.

Модели для прогнозирования гипогликемии включают:

1. **Алгоритмы компьютерного зрения** - анализируют данные с камер или других визуальных датчиков для правильного подсчета углеводов пищи.

2. **Физиологические модели прогнозирования** - используют математическое моделирование для предсказания будущих уровней глюкозы на основе текущих метаболических показателей.

3. **Правило-ориентированные системы** - применяют набор заранее определенных критериев и пороговых значений для идентификации риска гипогликемии.

Каждый из этих подходов имеет свои преимущества и ограничения. Физиологические модели требуют точных входных данных, но обеспечивают хорошую интерпретируемость результатов. Алгоритмы машинного обучения могут выявлять сложные нелинейные зависимости, но требуют больших объемов данных для обучения. Эвристические системы просты в реализации, но могут не учитывать индивидуальные особенности пациентов. Современные системы часто комбинируют несколько подходов для повышения точности и надежности рекомендаций.

Определение проблемы

Входные данные представляют собой набор пар $S = \{(t_i, y_i), \ldots\}$ где t_i — это время, когда человек делает измерения уровня сахара в крови, событие типа (или маркер) y_i - это показания сахара в крови в момент времени t_i.

Сравнение с моделью RMTPP

Модели, которые прогнозируют уровень глюкозы используют большее количество данных (например физическую активность человека в данный момент), которые зачастую в реальной жизни сложно получить в полном объеме (например человек может просто забыть указать что он только что делал, что может повлиять на изменение уровня сахара в крови), отсюда идет ухудшение качества предсказаний модели.

Ключевые отличия нашей модели:

- **Единый фреймворк** для времени и маркировки (глюкоза, инсулин, углеводы)
- Использование **истории событий**
- Прогнозирование **времени следующего измерения** как часть модели
- Адаптация к **индивидуальным паттернам** измерений
- Использование меньшего количества данных, использующихся для прогнозирования уровня сахара в крови (глюкоза, инсулин, углеводы)

Комментарии вводимых понятий и определений

1. Ключевые понятия

- **Сахарный диабет 1 типа(СД1)** - хроническое заболевание,возникающее в результате дисфункции бета-клеток поджелудочной железы и дефицита инсулина.

- **Гипогликемия** - снижение уровня глюкозы в крови менее 3,5 ммоль/л. При снижении уровня глюкозы в крови ниже 2,5 ммоль/л возможно развитие гипогликемической комы.

- **Гиперликемия** - повышение глюкозы в крови более чем на 5,7 ммоль/л. Резкое увеличение в крови больного диабетом количества глюкозы (свыше 33 ммоль/л) главная причина диабетической комы.

- **Гликированный гемоглобин (HbA1c)** — это биохимический показатель, отражающий **среднюю концентрацию глюкозы в крови** за период до 3 месяцев.

- **автоматизированная система поддержки принятия решений (DSS)** - предназначены для того,чтобы помочь людям лучше управлять своим диабетом,консультируя по вопросам ведения медикаментозной терапии, предупреждая о медицинских осложнениях, обеспечивая визуализацию данных,упрощая подсчет количества углеводов предоставляя информацию о диабете и помогая скорректировать повседневное поведение и образ жизни. Выделяют два типа DSS:
  - коррекция инсулинотерапии
  - профилактика гипогликемии

- **Повторяющиеся отмеченные временные точечные процессы (RMTPP)** - класс моделей для анализа последовательностей событий, где каждое событие имеет:
  - Временную метку (когда произошло)
  - Маркировку (дополнительные характеристики)

- **Событие измерения** - в нашем контексте включает:
  - Факт измерения уровня глюкозы
  - Полученное значение (в ммоль/л)
  - Введённый инсулин (в единицах)
  - Потреблённые углеводы (в граммах)

- **История событий** - временной ряд всех предыдущих измерений пациента с их параметрами

- **Loss-функция Mean Squared Error (MSE)** — это стандартная функция потерь для задач регрессии, которая вычисляет среднее значение квадратов разностей между предсказанными и истинными значениями.

  Вот ее формула:

$$\mathrm{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

  где:
  - n — количество предсказаний,
  - y_i — метка,

– $\hat{y}_i$. — предсказанное значение.

- **Пуассоновский процесс:** Интенсивность $\lambda(t)$ постоянна и не зависит от истории событий:

$$\lambda(t) = \lambda_0 \tag{1}$$

Вероятность наступления события в интервале $[t, t + dt)$:

$$P(\text{событие в } dt) = \lambda_0 dt + o(dt) \tag{2}$$

- **Процесс Хоукса:** Само-возбуждающийся процесс с переменной интенсивностью:

$$\lambda(t) = \mu + \alpha \sum_{t_i < t} e^{-\beta(t - t_i)} \tag{3}$$

где:

  – μ – базовая интенсивность
  – α – сила влияния прошлых событий
  – β – скорость затухания влияния

2. Практическая значимость понятий

Введение этих понятий обусловлено следующими реальными ситуациями:

1. **Неравномерность измерений** - пациенты с диабетом 1 типа обычно делают измерения не через равные промежутки времени, а в зависимости от:

   - Текущего самочувствия
   - Приёма пищи
   - Физической активности
   - Предыдущих показателей глюкозы
   - Чувствительность к инсулину

   Точечные процессы адекватно отражают такую неравномерную временную структуру.

2. **Комплексность управления диабетом** - каждое измерение связано с тремя взаимозависимыми параметрами (глюкоза, инсулин, углеводы), что требует маркировки событий.

3. **Персонализированные рекомендации** - модель должна учитывать индивидуальные паттерны поведения пациента, что обеспечивается анализом полной истории событий.

4. **Прогнозирование рисков** - позволяет предсказывать не только время следующего измерения, но и критические состояния (гипо- и гипергликемию) по отклонениям от нормальных паттернов.

Методология

1. Архитектура RMTPP

Архитектура модели Recurrent Marked Temporal Point Process (RMTPP) для заданной последовательности событий $S = \{(t_j, y_j)\}_{j=1}^{n}$ работает следующим образом:

1. При обработке j-го события маркер y_j сначала преобразуется в скрытое пространство с помощью embedding-слоя:

$$e_j = \text{Embedding}(y_j) \tag{4}$$

2. Полученный вектор e_j и временные характеристики t_j передаются в рекуррентный слой:

$$h_j = \text{RNN}(h_{j-1}, [e_j; \phi(t_j)]) \tag{5}$$

   где $\phi(\cdot)$ - временное embedding, а $[;]$ обозначает конкатенацию.

3. Рекуррентный слой изучает представление h_j, которое кодирует нелинейные зависимости от предыдущих событий.

4. На основе h_j модель предсказывает:

   - Маркер следующего события:

$$\hat{y}_{j+1} = f_y(h_j) \tag{6}$$

   - Время следующего события:

$$\hat{t}_{j+1} = f_t(h_j) \tag{7}$$

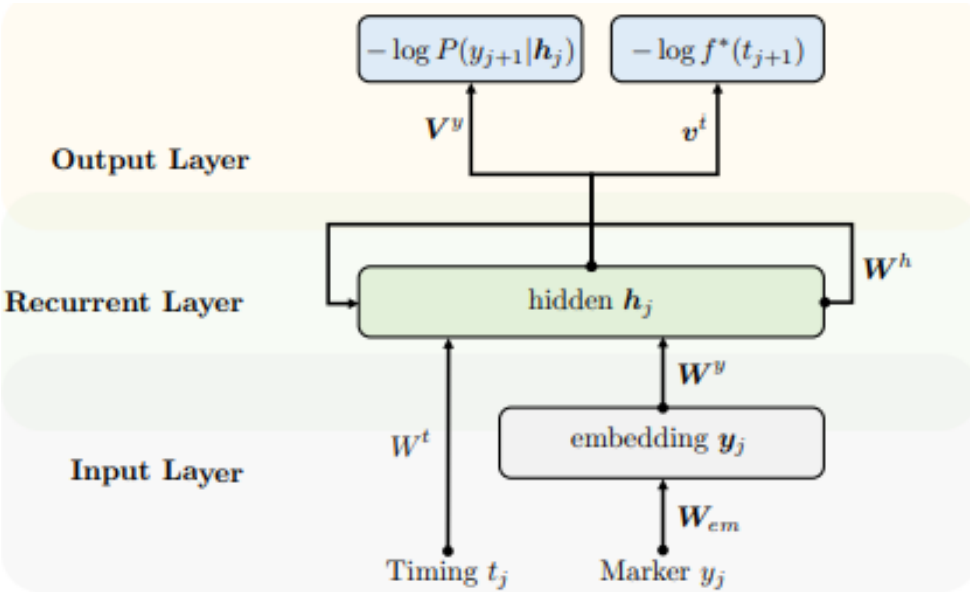

Рис. 1: Схема архитектуры RMTPP. Входные маркеры y_j и временные метки t_j преобразуются в скрытое пространство, обрабатываются рекуррентной сетью и используются для предсказания следующего события.

2. Реализация RMTPP

```
class RMTPP(nn.Module):
    def __init__(self, input_dim, hidden_dim):
        super(RMTPP, self).__init__()
        self.lstm = nn.LSTM(input_dim, hidden_dim, batch_first=True)
        self.dropout = nn.Dropout(0.1)

        self.linear1 = nn.Linear(hidden_dim, hidden_dim//3)
        self.F = nn.ReLU()
        self.linear2 = nn.Linear(hidden_dim//3, 4)


    def forward(self, x):
        lstm_out, _ = self.lstm(x)
        last_hidden = lstm_out[:, -1, :]
        last_hidden = self.dropout(last_hidden)
        output = self.linear2(self.F(self.linear1(last_hidden)))

        return output
```

- **Архитектура**:
  - LSTM-слой для обработки временных последовательностей
  - 2 полносвязных слоя с активацией ReLU
  - Dropout-регуляризация ($p = 0.1$), предназначеная для устранения переобучения модели.
- **Параметры**:
  - `input_dim`: размерность входных данных
  - `hidden_dim`: размерность скрытого состояния LSTM
- **Особенности**:
  - Вход: 3D-тензор (пакет, длина последовательности, размерность)
  - Использует последнее скрытое состояние LSTM
  - Выход размерности 4 (предсказание времени и маркеров)

3. Loss-функция

```
def masked_mse_loss(predictions, targets):
    # Loss для события (индекс 0)
    loss_1 = torch.nn.functional.mse_loss(
        predictions[:,0],targets[:, 0])

    # Loss для глюкозы
    loss_2 = torch.nn.functional.mse_loss(
        predictions[:,1],targets[:, 1])
    if loss_1 + loss_2 < 1e-6:
        return 1e-6
    return (loss_1 + loss_2)/2
```

Функция вычисляет комбинированную ошибку предсказания для двух целевых переменных, используя *среднеквадратичную ошибку* (MSE).

Параметры:

- `predictions`: тензор предсказанных значений размерности $[N, 2]$
- `targets`: тензор истинных значений размерности $[N, 2]$

Функция считает loss1 для времени и loss2 для глюкозы, а затем выводит среднюю арифметическую ошибку этих двух значений

4. Датасет

Перед тем как обучить модель, я изменил исходный датасет, представляющий из себя ежеминутные измерения уровня глюкозы, инсулина и углеводов. Я смоделировал ситуацию, что человек будет проводить измерения не каждую минуту, а через какие-то промежутки времени, которые будут зависеть от показаний уровня глюкозы в крови. Таким образом я получил новый датасет, в котором добавлен новый столбец, в котором указано время измерения. Следующий график описывает каким образом я выбирал данные из исходной таблицы.По оси X уровень сахара в крови, по оси Y математическое ожидание и дисперсия нормального распределения. Таким образом, исходя из графика, следующее время, в которое я должен провести измерение, определяется следующей формулой:

$$t_i = t_{i-1} + N(\nu_{i-1}, \sigma_{i-1})$$

где:

- t_{i-1} — время последнего измерения,
- $N(\nu, \sigma)$ — нормальное распределение с математическим ожиданием ν и стандартным отклонением σ,
- ν_{i-1} и σ_{i-1} определяются с помощью графика.

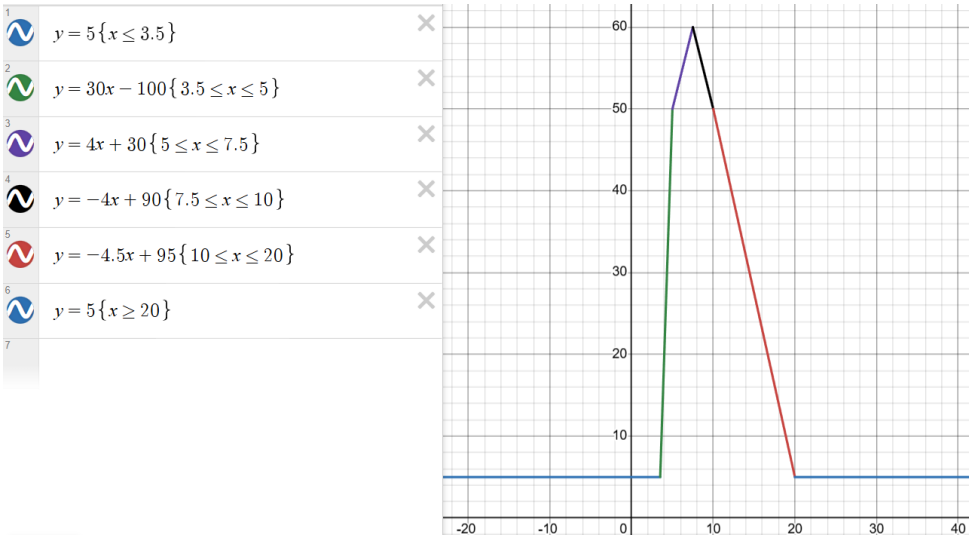

Рис. 2: Метод выборки данных в зависимости от уровня глюкозы

5. Создание выборок

Предобработка данных.

Загрузка и подготовка данных

- Загрузка данных из CSV-файла (`output21k.csv`)
- Преобразование временных меток из формата "HH:MM:SS"в минуты
- Удаление вспомогательных столбцов (`hours`, `minutes`, `seconds`)

Нормализация признаков

- Применение `StandardScaler` для стандартизации данных
- Масштабирование признаков к нулевому среднему и единичной дисперсии

Формирование последовательностей

- Создание временных окон фиксированной длины (`seq_length=3`)
- Функция `create_sequences` генерирует:
  - Входные последовательности (X) - временные окна
  - Целевые значения (y) - следующий шаг после окна

Разделение данных

- 70% - тренировочный набор
- 15% - валидационный набор
- 15% - тестовый набор

Подготовка для PyTorch

- Преобразование массивов NumPy в тензоры PyTorch
- Создание `DataLoader` для:
  - Пакетной обработки (`batch_size=32`)
  - Эффективной загрузки данных

Ниже представлен код реализации.

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import StandardScaler
import torch
from torch.utils.data import DataLoader, TensorDataset

# Загрузка данных
df = pd.read_csv('output21k.csv')
```

```
# Преобразование времени
df[['hours', 'minutes', 'seconds']] = df['Time'].str.split(':', expand=True).astype
df['Time'] = df['hours'] * 60 + df['minutes'] + df['seconds']

# Выбор признаков и нормализация
features = df.drop(columns=['hours', 'minutes', 'seconds']).values
print(features[4:33])
scaler = StandardScaler()
scaled_features = scaler.fit_transform(features)

# Параметры последовательности
seq_length = 3 # Длина временного окна
batch_size = 32

# Создание последовательностей
def create_sequences(data, seq_length):
    xs, ys = [], []
    for i in range(len(data)-seq_length-1):
        x = data[i:(i+seq_length)]
        y = data[i+seq_length]
        xs.append(x)
        ys.append(y)
    return np.array(xs), np.array(ys)

X, y = create_sequences(scaled_features, seq_length)

# Разделение на train/valid/test
train_size = int(0.7 * len(X))
valid_size = int(0.15 * len(X))
test_size = len(X) - train_size - valid_size

X_train, y_train = X[:train_size], y[:train_size]
X_valid, y_valid = X[train_size:train_size+valid_size], y[train_size:train_size+val
X_test, y_test = X[train_size+valid_size:], y[train_size+valid_size:]

# Преобразование в тензоры PyTorch
X_train = torch.FloatTensor(X_train)
y_train = torch.FloatTensor(y_train)
X_valid = torch.FloatTensor(X_valid)
y_valid = torch.FloatTensor(y_valid)
X_test = torch.FloatTensor(X_test)
y_test = torch.FloatTensor(y_test)

# Создание DataLoader
train_data = TensorDataset(X_train, y_train)
train_loader = DataLoader(train_data, batch_size=batch_size, shuffle=False)

valid_data = TensorDataset(X_valid, y_valid)
valid_loader = DataLoader(valid_data, batch_size=batch_size, shuffle=False)
```

```
test_data = TensorDataset(X_test, y_test)
test_loader = DataLoader(test_data, batch_size=batch_size, shuffle=False)
```

Эксперименты

Здесь приведены результаты сравнения модели RMTPP и полносвязной модели. Для обучения этих моделей использовался один и тот же датасет и одну и ту же функцию лосса (MSE). Также сравнива.тся прогнозы времени этих моделей с процессами Пуассона и Хоукса.

1. Результаты сравнения

На рис. 3a и рис. 3b представлена динамика функции потерь для моделей RMTPP и Linear на различных эпохах обучения (по оси X указано количество эпох обучения, по оси Y указаны значения лосс-функции):

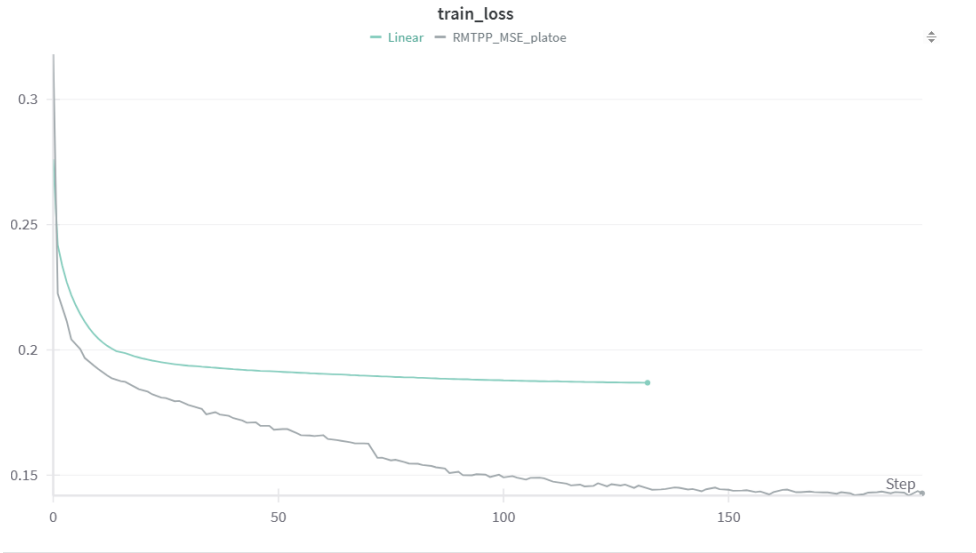

(a) Обучающая выборка

(b) Валидационная выборка

Рис. 3: Сравнение потерь на обучающей и валидационной выборках

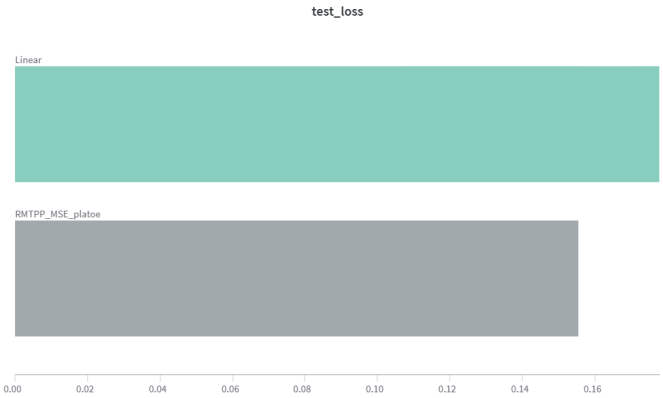

Рис. 4: Тестовая выборка

2. Анализ результатов

Как видно из графиков:

- На обучающей выборке (рис. 3a) модель RMTPP демонстрирует более быструю сходимость
- На валидационных данных (рис. 3b) модель RMTPP демонстрирует более быструю сходимость
- На тестовой выборке (рис. 4) RMTPP показывает статистически значимое улучшение

Таблица 1: Сравнение итоговых значений функции потерь

Модель	Train Loss	Val Loss	Test Loss
RMTPP	0.142	0.154	0.155
Linear	0.188	0.185	0.178

Таким образом, модель RMTPP показала лучшие результаты по сравнению с обычной полносвязной моделью.

После тестирования модели на сгенерированном датасете пациентов с диабетом 1 типа были получены следующие результаты:

- Средняя ошибка предсказания времени следующего измерения: 70 минут
- Средняя ошибка предсказания уровня глюкозы: 5.9 мг/дл

3. Прогноз времени для различных процессов

На рисунке 3 График отображает ошибку прогнозирования (MSE) для четырех методов: RMTPP (Recurrent Marked Temporal Point Process); Linear (Полносвязная модель); Poisson (Пуассоновский процесс); Hawkes (Процесс Хоукса)

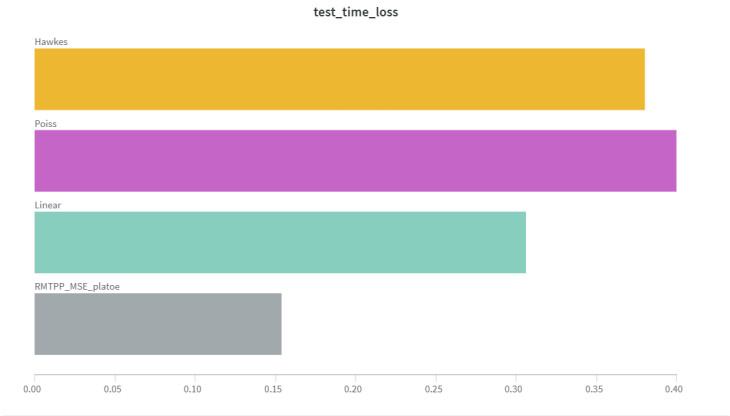

Рис. 5: Тестовая выборка

Таблица 2: Сравнение точности моделей

Метод	Loss Time
RMTPP	0.153
Linear	0.306
Poisson process	0.4
Hawkes process	0.38

Список литературы

[1] Nan Du, Hanjun Dai, Rakshit Trivedi, Utkarsh Upadhyay, Manuel Gomez-Rodriguez, Le Song. Recurrent Marked Temporal Point Processes, 2016

[2] Nichole S. Tyler and Peter G. Jacobs. Artificial Intelligence in Decision Support Systems for Type 1 Diabetes, 2020